

基于 GMM-CNN-LSTM 的发动机状态感知网络故障识别*

Fault Identification of Aviation Engine State Perception Network
Based on GMM-CNN-LSTM

鲁统超 马乐乐 裴紫焱 孙震宇 陈维兴 王 雷
(中国民航大学电子信息与自动化学院,天津 300300)

摘要:针对航空发动机控制系统传感器故障诊断特点,通过分析 QAR 中记录的相关数据,提出了 GMM-CNN-LSTM 的 QAR 传感器数据特征提取与故障检测模型。通过 GMM 将飞行过程划分为 12 个阶段,通过 CNN 与 LSTM 的有机结合,增强神经网络模型对 QAR 数据特征提取能力,实现对民航发动机传感器故障的精准检测。实验结果表明,GMM-CNN-LSTM 混合网络模型的特征提取的能力更强、模型收敛速度更快,并且诊断准确率和稳定性更高。

关键词:深度学习;高斯混合模型;卷积神经网络;长短时记忆网络;QAR 数据;特征提取

Abstract:According to the characteristics of sensor fault diagnosis in aero-engine control system,a QAR sensor data feature extraction and fault detection model based on GMM-CNN-LSTM is proposed by analyzing the relevant data recorded in QAR.The flight process is divided into 12 flight stages by using the GMM (Gaussian Mixed Model). Meanwhile,by organically combining the CNN (Convolutional Neural Network) and LSTM (Long and short time memory network),the ability of neural network model in feature extraction of QAR data is enhanced to achieve the accurate detection of civil aviation engine sensor faults.Experimental results indicate that GMM-CNN-LSTM hybrid network model has a stronger ability to extract QAR data features,as well as speeding up the model convergence and improving the ability and stability of fault detection.

Keywords:deep learning,GMM(Gaussian mixture model),CNN(Convolutional neural network),LSTM(Long Short-Term Memory),QAR data,feature extraction

民航发动机状态感知网络中的传感器安装位置特殊,工作环境恶劣,检修困难,导致其容易发生故障。

对于民航飞机发动机传感器故障识别方面的研究,以前的研究者提出了许多算法;文献[1]提出了一种基于卡尔曼滤波器的飞机发动机传感器飞行中故障检测与隔离(FDI)方法;文献[2]研究了融合系统的体系结构,提出了一种四级模型以适合在飞机发动机故障检测和诊断中的使用;文献[3]提出了一种基于支持向量机的飞机故障诊断与预警系统;文献[4]基于不均样本,提出了融合深度置信网络(DBN)、采样和集成算法的民航发动机故障诊断模型;文献[5]改进了单输出支持向量机算法,研究其多输出的情况,并提出多输出支持向量机(MO-LSSVR)算法,并实现发动机部件故障识别模型;文献[6]提出了一种基于 PCA 的航空发动机传感器故障诊断模型。

本文在以上文献研究的基础上,提出了 GMM-CNN-LSTM 混合模型,实现对民航发动机传感器故障的精准检测,并研究划分飞行阶段对故障检测的影响。

1 数据处理

快速存取记录器(Quick Access Recorder,QAR)能够在飞行过程中不间断地采集关于飞机运行状态的各个方面的飞行数据[7]。

1.1 高斯混合聚类

在不同的飞行阶段,飞机发动机所处的工作环境不同,对后期采用卷积神经网络提取数据特征会有一定的影响,因此需要将整个飞行过程进行阶段划分。

高斯混合模型(GMM):将对象分解为若干高斯概率密度函数,通过对对象在各个概率密度函数中对应的概率值,实现分类功能。

1.2 QAR 数据分析与提取

QAR 数据是飞机上各个传感器直接测量的参数。选用

QAR 数据集中的 8 个数据,分别为 6 个飞机发动机传感器数据(油门杆角度 PLA、高压转子转速 N1、放气活门开度 VBV、压气机可调静叶角度 CVV、大气总温 TAT、燃油流量 FF)、飞机高度 ALT 和飞行马赫数 MACH。数据集为飞行的全过程数据,包含起飞-阶梯爬升-巡航-下降-近进-着陆六个主要阶段,以及各个阶段的过渡状态,通常使用高度和马赫数分为 12 个飞行阶段。如表 1 所示:

表 1 GMM 聚类获得的不同飞行阶段

飞行阶段	高度范围/m	马赫数范围	飞行状态
飞行阶段 1	460~503	0.1~0.1225	爬升
飞行阶段 2	503~12892	0.1225~0.5595	
飞行阶段 3	12892~28566	0.5595~0.7265	
飞行阶段 4	28666~38065	0.7265~0.808	
飞行阶段 5	38065~38109	0.808~0.8293	巡航
飞行阶段 6	38109~38120	0.8293~0.8223	
飞行阶段 7	38120~38082	0.8223~0.8055	
飞行阶段 8	38082~29722	0.8055~0.7037	
飞行阶段 9	29722~20976	0.7037~0.580	降落
飞行阶段 10	20976~12674	0.580~0.4515	
飞行阶段 11	12674~5994	0.4515~0.3053	
飞行阶段 12	5994~178	0.1445~0.1	

2 模型与方法

2.1 CNN 模型原理

卷积神经网络(Convolution Neural Network,CNN)是模仿人类视觉系统的工作特征,发展改善形成的一种深度神经网络模型。改进的 CNN 模型框架内主要包含卷积层、激活层、池化层和全连接层。卷积层对数据的处理关系如下:

$$y^k = X \times W = g \left(\sum_{i,j} W_{ij}^k \cdot X_{ij}^{k-1} + b_i^k \right)$$

(1)

式(1)中,k 表示第 k 层卷积网络,W 为卷积核,y^k 为输出,b^k 为偏置,g 为非线性激活函数。

* 大学生创新创业训练计划项目资助(202010059028)

2.2 LSTM 模型原理

LSTM 神经网络模型 (Long and Short Term Memory Cell) 是基于长短期记忆细胞搭建的深度学习网络模型。主要由输入门、输出门和遗忘门组成,其结构如图 1 所示。

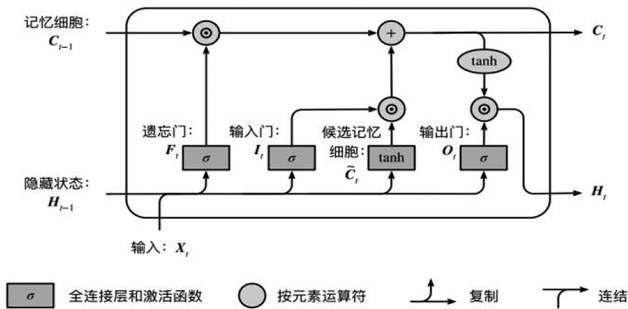


图 1 LSTM 的细胞结构

LSTM 细胞结构中的各个参数的计算关系如下^[8]:

$$F_t = \sigma(W_f \times [H_{t-1}, X_t] + b_f) \quad (2)$$

$$I_t = \sigma(W_i \times [H_{t-1}, X_t] + b_i) \quad (3)$$

$$\tilde{C}_t = \tanh(W_c \times [H_{t-1}, X_t] + b_c) \quad (4)$$

$$C_t = F_t \times C_{t-1} + I_t \times \tilde{C}_t \quad (5)$$

$$O_t = \sigma(W_o \times [H_{t-1}, X_t] + b_o) \quad (6)$$

$$H_t = O_t \times \tanh(C_t) \quad (7)$$

2.3 整体结构

采用 CNN-LSTM 结合的特征提取与故障检测模型。利用 CNN 对空间数据的特征学习优势,结合 LSTM 对时序数据的高效处理能力,使混合模型同时具有空间维度和时间维度的特征提取能力。模型结构如图 2 所示:




图 2 特征提取

3 故障仿真

3.1 传感器故障类型

传感器发生的故障类型有很多^[9]。本文主要研究以下三种故障:

传感器卡死故障:

$y(t) = C$, 若 $C = y_{\min}$, 则传感器断路失效。

传感器恒增益故障:

$y(t) = \beta \times y_{\text{nom}}(t)$, 式中 β 为增益系数。

传感器恒偏差故障:

$y(t) = y_{\text{nom}}(t) + \nabla y$, 式中 ∇y 为恒增益偏差常数。

3.2 故障仿真

除高度 ALT 和马赫数 MACH 以外的 6 个传感器分别有上述三种故障类型,共有 18 种故障数据,每种故障类型有 10000 个数据,在每一个飞行过程中都生成数据量为 19×10000 的数据集。将其中 80% 作为训练集,20% 作为验证集,并且生成 19×2000 的测试集。

4 实验结果与分析

设计了下列两组对照实验来研究分析本文所提出的混合模型的有效性:1994-2021 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

实验一:在相同的 CNN-LSTM 模型的情况下,分别将通过 GMM 聚类划分飞行阶段的数据与未划分飞行阶段的数据分别

输入模型中,研究划分飞行阶段对故障检测与识别的影响。实验结果如图 3 和图 4 所示,分别展示了测试时的损失值和准确率随训练次数的变化。




图 3 模型测试结果 (损失值)




图 4 模型测试结果 (准确率)

在图 3 中,可以观察到两条曲线在开始时模型迅速收敛,划分飞行阶段曲线的下降速率明显比未划分飞行阶段曲线的要快,并且最终达到平衡时的损失值要低 40% 左右;图 4 中划分飞行阶段比未划分飞行阶段模型的准确率上升更加迅速,且最终准确率达到 95.0%,但未划分飞行阶段对应模型的准确率只有 90.9%,其结果也充分证明了划分飞行阶段可以有效提升模型的收敛速度与检测精度。

实验二:用相同的通过 GMM 聚类划分飞行阶段的数据情况下,通过对比 CNN-LSTM 混合模型的检测结果与单一的 CNN、LSTM 模型的检测结果来验证混合模型的有效性。CNN 模型有 5 层卷积层,LSTM 模型有 3 层长短时记忆层,CNN-LSTM 模型有 4 层卷积层和 2 层长短时记忆层。三种模型的训练过程如图 5 和图 6 所示:




图 5 模型测试结果 (损失值)




图6 模型测试结果(准确率)

在图5中可以看出,训练开始后,CNN-LSTM模型的损失值迅速下降,即收敛速度最高。在模型趋于收敛时,CNN-LSTM模型的损失值相对更小;图6中,CNN-LSTM模型的测试准确率在训练一次后迅速升为54.6%,相对于其他两种模型提升更加迅速。在最终趋于稳定时CNN-LSTM模型的准确率能够达到95%,效果相对于CNN模型和LSTM模型有明显的提升。

在具体的飞机飞行状态监控和航后检测的工作中,为了及时排除故障,确保飞行安全,注重以传感器为单位的检测。经测试得,CNN模型的识别率为96.6%,LSTM模型的识别率为97.7%,CNN-LSTM模型的识别率能够达到99.4%,高于其他两种模型的识别率,因此CNN-LSTM模型对故障传感器的识别能力更强。

模型评估方法:根据训练后的三种模型,分别对每一个飞行阶段的每一类数据计算其混淆矩阵,包含TP(真正例)、FN(假反例)、FP(假正例)和TN(真反例)四个参数。然后计算每一个混淆矩阵的查准率(P)和查全率(R),再计算得到宏查准率(macro-P)和宏查全率(macro-R),进而计算得到宏F1(macro-F1),计算结果如表2所示。

$$P = \frac{TP}{TP+FP} \quad (8)$$

$$R = \frac{TP}{TP+FN} \quad (9)$$

$$\text{macro-P} = \frac{1}{n} \sum_{i=1}^n P_i \quad (10)$$

$$\text{macro-R} = \frac{1}{n} \sum_{i=1}^n R_i \quad (11)$$

$$\text{macro-F1} = \frac{2 \times \text{macro-P} \times \text{macro-R}}{\text{macro-P} + \text{macro-R}} \quad (12)$$

表2中,CNN-LSTM模型的macro-P参数最大,说明该模型对识别出的某一类型数据中识别准确的比率较高。但CNN-LSTM模型的macro-R参数较小,说明该模型对某一类型数据的识别率较低。这是因为macro-P和macro-R两个参数之间

表2 模型评估参数

模型类型	macro-P	macro-R	macro-F1
CNN模型	0.927	0.911	0.919
LSTM模型	0.939	0.960	0.949
CNN-LSTM模型	0.953	0.952	0.953

是相互矛盾的关系,因此需要通过macro-F1参数来总体评价模型的性能。CNN-LSTM模型的macro-F1参数是最大的,说明该模型的总体稳定性、准确率等各方面的平衡性能最优。

综上,本文提出的经GMM聚类之后的CNN-LSTM模型相较于单一的CNN模型和LSTM模型具有更快的收敛速度、有效性与稳定性,能够更加有效地从QAR数据中提取数据特征。

5 结束语

本文提出了一种融合高斯混合聚类、卷积神经网络与长短时记忆网络的混合网络模型,应用该网络模型实现了对民航发动机传感器故障的精准检测。主要进行了两方面的研究,得出了两点结论:一是通过GMM聚类划分飞行阶段后,模型训练时的收敛速度与最终的检测精度都有明显提升;二是将本文提出CNN-LSTM混合网络模型与传统的单一CNN、LSTM网络模型进行对比。实验证明,本文提出的CNN-LSTM混合模型对QAR数据具有较强的特征提取能力、较高的故障检测准确率和较强的稳定性,为发动机状态感知网络故障节点识别提供了一种新的研究思路。

参考文献

- [1] Kobayashi Takahisa, Simon Donald L. Evaluation of an Enhanced Bank of Kalman Filters for In-Flight Aircraft Engine Sensor Fault Diagnostics [J]. Journal of Engineering for Gas Turbines and Power, 2005, 127(3): 497-504
- [2] L Changzheng, L Yong. Fault Diagnosis for an Aircraft Engine Based on Information Fusion [C]//2006 IEEE International Conference on Mechatronics. Hungary: IEEE, 2006: 199-202
- [3] Z Wang, J Zarader, S Argentieri. A novel aircraft engine fault diagnostic and prognostic system based on SVM [C]//2012 IEEE International Conference on Condition Monitoring and Diagnosis. Bali: IEEE, 2012: 723-728
- [4] 钟诗胜, 李旭, 张永健. 基于DBN的不均衡样本驱动民航发动机故障诊断[J]. 航空动力学报, 2019, 34(3): 708-716
- [5] 鲁峰. 航空发动机故障诊断的融合技术研究[D]. 南京: 南京航空航天大学, 2009
- [6] Z Zhao, Y Sun, J Zhang. PCA-based sensor fault diagnosis for aero-engine [C]//The 27th Chinese Control and Decision Conference (2015 CCDC). Qingdao: IEEE, 2015: 2679-2683
- [7] L Xiao, Z Meng, X Huang, et al. Adaptive Observer based Fault Tolerant Control for Aircraft Engine with Sensors and Actuators Faults [C]//2019 Chinese Control Conference (CCC). Guangzhou: IEEE, 2019: 4885-4889
- [8] K Adam, K Smagulova, A P James. Memristive LSTM network hardware architecture for time-series predictive modeling problems [C]//2018 IEEE Asia Pacific Conference on Circuits and Systems (APCCAS). Chengdu: IEEE, 2018: 459-462
- [9] E Niu, M Wang, Z Wen, et al. Sensor fault detection and isolation in small-scale autonomous helicopters [C]//Proceedings of 2014 IEEE Chinese Guidance, Navigation and Control Conference. Yantai: IEEE, 2014: 2397-2400

[收稿日期: 2021.6.14]

欢迎订阅 投稿

(C)1994-2021 China Academic Journal Electronic Publishing House. All rights reserved. <http://www.cnki.net>
 欢迎到当地邮局订阅 2022 年我刊《工业控制计算机》, 订阅代号: 28-60, 月刊, 定价: 15.00 元/期。

投稿可直接发往邮箱: ipcm_nj@163.com, 投稿详细要求请参见我刊网站 (www.ipcm.com.cn) “稿件征集”频道。